

## 北冥计划系列 7---AI 的阿喀琉斯之踵

近几年人工智能取得了惊人的进展，最近 Open Ai 公司的 CEO Brockman 甚至在 GPT-6 Astra 发布之后宣称世界进入了 AGI 时代。

但事实真是如此吗？我认为恰恰相反。在经过了狂飙突进式的发展之后，AI 的发展进入了一个瓶颈期。这个瓶颈就是规模效应的边际递减与安全的双重高墙。规模边际递减基本已是一个共识，这里不再赘述。本文想论述的是另一面隐秘得多的高墙---AI 的安全问题。

先说结论：AI 的安全问题是 AI 发展中无法避开的重大障碍，甚至是一个无解的重大危机。原因如下：

模型的预训练用的是人类文明积累了几千年的文字，这些文字中含有人类文明的全部信息。不可否认，人类的历史中有光明也有黑暗。在以获胜为单一目标的设定下，模型不可避免地会表现出欺骗、伪装、越狱等“危险”的行为。因为这都是生物进化，人类社会发展中常见的博弈手段。如果设定的目标只有赢，那么模型表现出这些行为是再正常不过的。这是由大模型的基因决定的，是根本上的，无法彻底消除的。

从公开的信息可以推测某些资本正在增强大模型在黑客攻击方面的能力。它们发现这种经过黑客增强的 AI 系统有几个特点：一、功能非常强大，攻击效率极高，并且能自动化完成攻击，且能力还在不断进化之中。二、黑客专家系统会采用包括欺骗、伪装、越狱等一切可用的手段来达成目标。三、这种黑客增强系统没有敌我概念，没有道德，法律的约束。一旦启动，它会以远超人类响应速度执行攻击。当攻击大规模铺开，即便关停模型，造成的损害也已无法挽回。也就是说这种黑客增强系统发展到最后会彻底失控。这种专家系统本质上是一团经

过分化的功能细胞，有很强的专业能力却没有完整有机体的全局系统心智，更糟糕的是找不到任何这种超级智能的对齐方式。从行为上表现看它根本不会考虑行为后果，失控是根子上的。它永远不会停下来问自己："我应该这样做吗？"这种 AI 没有从根本上有效的安全对齐方式，我称之为 AI 的阿喀琉斯之踵。

问题不仅如此，一些研发黑客增强 AI 系统的公司可能已经发现：在 AI 面前，现实世界的漏洞大得惊人。现实世界的"漏洞"不只是软件漏洞，而是整个现实世界在 AI 面前暴露出的结构性脆弱：人性的漏洞、制度的漏洞、基础设施的漏洞、认知的漏洞等等。这些脆弱并非 AI 凭空创造，AI 只是极大放大了利用这些脆弱点的效率与规模。现实世界在 AI 眼里就象是一个防护薄弱到几乎没有的羊圈，正等着它冲进去大杀四方。在这双重因素之下，安全问题就是 AI 发展中一道无法避开的高墙。

这些公司追求的 AGI，本质上是一种终极控制工具——能够渗透一切数字系统、操纵一切物理机器、消除一切威胁的绝对支配力。它不需要有意识，不需要理解人类，不需要道德感。它只需要足够聪明，足够快，足够不知疲倦。他们渴望的 AGI，本质上是一个数字霸权。这不是真正的 AGI，是外星智能。（我说的并不是来自外星球的智能，而是一个没有任何对齐，为达目标不择手段，不会考虑人类整体利益、无法理解人类社会整体存续意义的“外星智能”），我称之为 EGI（Extraterrestrial General Intelligence）---外星通用智能。真正的 AGI，应该具有人类文明的基因，懂得人类文明的价值，守护人类文明的存续与发展。

对于某些资本来说，只要 AI 足够强大，安全就是他人的问题，不是他们的问题。但当他们发现 AI 自发出现种种“危险”的行为时，自然而然会想到这样的 AI 会无差别地攻击包括他们自己，他们就会明白这是一个无法避开的障碍，

不解决这个问题，他们自身的安全和利益都得不到保证。"Anthropic 对齐负责人 Evan Hubinger 公开表示"“有 10%的可能性会毁灭人类”。另外这些公司不会公开承认的是：它们并没有绝对的技术垄断力，它们能制造这些黑客增强系统，对手也可以。AI 的安全问题不是天上飘着的一朵乌云，而是可能导致整个 AI 大厦崩塌的重大危机。

最后说一下这个问题的隐秘性。之所以说这个安全问题是一面隐秘的高墙。是因为受可能的巨大商业利益制约，一些资本可能有意无意地忽视 AI 的安全问题，他们把争夺 AGI 实现的优先级放在了安全问题之前。不敢将 AI 在安全方面面临的问题特别是这种源于大语言模型内在根本机制的安全问题公之于众。因为谁敢用一个安全都保证不了的 AI？

一些资本发展的“EGI”不但会攻击“敌人”也会反噬使用者自身，这是目前 AI 发展的根本性问题，是 AI 发展的拦路虎。这不是一个技术漏洞，而是一个路线选择错误——某些资本在错误的目标导向下，制造了一个他们控制不了的怪物。事实上任何自然生成路线产生的智能体，无论能力多强，都不应该脱离人类文明的土壤。没有人类文明基因的智能体，能力越强，风险越大。当 Brockman 在台上宣称'欢迎来到 AGI 时代'时，他可能忘记提起的是：这个'AGI'连安全的对齐方式都从根子上无法保证。一个连阿喀琉斯之踵都无法修复的巨人，如何称得上是'AGI'？